

PREDIÇÃO DE DOENÇAS CARDÍACAS UTILIZANDO INTELIGÊNCIA ARTIFICIAL

INTEGRANTES

Douglas Kenji Matsumoto - RA: 23403549-2

Contextualização do tema escolhido

As doenças cardiovasculares estão entre as principais causas de morte no mundo. A utilização de técnicas de Inteligência Artificial pode auxiliar profissionais da saúde na identificação precoce de pacientes com maior probabilidade de desenvolver doenças cardíacas, contribuindo para diagnósticos mais rápidos e precisos.

Problema

Dado um conjunto de características clínicas de pacientes, o objetivo deste trabalho é desenvolver modelos capazes de classificar se um indivíduo possui ou não doença cardíaca.

Hipótese

Eu acredito que diferentes algoritmos de Inteligência Artificial apresentarão desempenhos distintos na classificação dos pacientes. Espera-se que o modelo SVM obtenha melhores resultados preditivos, enquanto a Árvore de Decisão ofereça maior interpretabilidade.

Descrição do dataset utilizado

Foi utilizado o Heart Disease Dataset, disponibilizado no Kaggle pelo usuário John Smith.

Fonte original: <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

O arquivo heart.csv utilizado nos treinos está disponível no repositório.

A variável alvo é denominada "target", em que:

0 = Sem doença cardíaca;

1 = Com doença cardíaca.

Antes do treinamento dos modelos, registros duplicados foram removidos para evitar vazamento de dados (data leakage) e garantir uma avaliação mais confiável dos algoritmos.

Métodos de Inteligência Artificial utilizados

Parte 1 – Árvore de Decisão

A Árvore de Decisão é um algoritmo supervisionado que constrói regras de decisão a partir dos atributos do conjunto de dados, permitindo interpretar facilmente o processo de classificação.

Parte 2 – Máquina de Vetores de Suporte (SVM)

O SVM é um algoritmo supervisionado que busca encontrar um hiperplano capaz de separar as classes com a maior margem possível. Para este trabalho, foi utilizado o kernel RBF juntamente com a padronização dos atributos por meio do StandardScaler.

Avaliação dos modelos

Os dados foram divididos em conjuntos de treinamento (80%) e teste (20%), utilizando estratificação das classes.

As métricas utilizadas para avaliação foram:


- Acurácia

- Precisão
- Recall
- F1-score
- Matriz de confusão


Resultados da Árvore de Decisão

Acurácia: 72,13%

Classe	Precisão	Recall	F1-score
Sem Doença	0,69	0,71	0,70
Com Doença	0,75	0,73	0,74



Árvore de Decisão - Heart Disease Dataset




Resultados do SVM

Acurácia: 77,05%

Classe	Precisão	Recall	F1-score
Sem Doença	0,77	0,71	0,74
Com Doença	0,77	0,82	0,79

Matriz de Confusão - SVM



Comparação dos resultados

Métrica	Árvore de Decisão	SVM
Acurácia	72,13%	77,05%
Precisão (Com Doença)	75%	77%
Recall (Com Doença)	73%	82%
F1-score (Com Doença)	74%	79%
Falsos Negativos	9	6

Observa-se que o SVM apresentou melhor desempenho geral, principalmente na identificação correta de pacientes com doença cardíaca, resultando em menor quantidade de falsos negativos.

Conclusão

Os resultados demonstraram que ambos os modelos foram capazes de realizar a classificação dos pacientes. Entretanto, o SVM apresentou desempenho superior nas métricas avaliadas, especialmente no recall da classe positiva, aspecto relevante em aplicações médicas. Por outro lado, a Árvore de Decisão destacou-se pela interpretabilidade, permitindo compreender as regras utilizadas pelo modelo durante o processo de classificação.

Dessa forma, conclui-se que o SVM foi o modelo mais adequado para este conjunto de dados sob a perspectiva preditiva, enquanto a Árvore de Decisão mostrou-se útil para fins explicativos e de apoio à tomada de decisão.

Arquivos do Projeto

- README.md: documentação completa do projeto.
- relatorio.pdf: relatório final da atividade.
- Slides-ia.pdf: slides utilizados na apresentação.
- arvore.ipynb: implementação da Árvore de Decisão.
- svm.ipynb: implementação do SVM.
- heart.csv: dataset utilizado nos experimentos.